21 | 采集引擎：实战接口抽象与模拟浏览器访问

2022-11-26 郑建勋 来自北京

《Go进阶 · 分布式爬虫实战》

课程介绍 >

讲述：郑建勋

时长 16:23　大小 14.96M

你好，我是郑建勋。

我们知道，接口是实现功能模块化、构建复杂程序强有力的手段。在上一节课，我介绍了接口的最佳实践和原理。这一节课，让我们在爬虫程序中实战接口，对采集引擎完成接口抽象。

接口抽象

在第 19 讲，我们已经将爬取网站信息的代码封装为了 fetch 函数，完成了第一轮的功能抽象。但是随着爬取的网站越来越复杂，加上服务器本身的反爬机制等原因，我们需要用到不同的爬取技术。例如后面会讲到的模拟浏览器访问、代理访问等。要想比较容易地切换不同的爬取方法，用模块化的方式对功能进行组合、测试，我们可以很容易地想到可以对爬取网站数据的代码模块进行接口抽象。

实战接口

具体的做法，我们首先要创建一个新的文件夹，将 package 命名为 collect，把它作为我们的采取引擎。之后所有和爬取相关的代码都会放在这个目录下。

复制代码

```
mkdir collect
touch collect/collect.go
```

接着我们要定义一个 Fetcher 接口，内部有一个方法签名 Get，参数为网站的 URL。后面我们还将对函数的方法签名进行改变，也会添加其他方法签名，比如用于控制超时的 Context 参数等。不过要知道的是，在 Go 语言中，对接口的变更是非常轻量的，我们不用提前费劲去设计。

复制代码

```
type Fetcher interface {
  Get(url string) ([]byte, error)
}
```

接下来，我们要定义一个结构体 BaseFetch，用最基本的爬取逻辑实现 Fetcher 接口：

复制代码

```
func (BaseFetch) Get(url string) ([]byte, error) {
  resp, err := http.Get(url)

  if err != nil {
    fmt.Println(err)
    return nil, err
  }

  defer resp.Body.Close()

  if resp.StatusCode != http.StatusOK {
    fmt.Printf("Error status code:%d", resp.StatusCode)
  }
  bodyReader := bufio.NewReader(resp.Body)
  e := DeterminEncoding(bodyReader)
  utf8Reader := transform.NewReader(bodyReader, e.NewDecoder())
  return ioutil.ReadAll(utf8Reader)
}
```

在 main.go 中定义一个类型为 BaseFetch 的结构体，用接口 Fetcher 接收并调用 Get 方法，这样就完成了使用接口来实现基本爬取的逻辑。


```
var f collect.Fetcher = collect.BaseFetch{}
body, err := f.Get(url)
```

模拟浏览器访问

上面 BaseFetch 的 Get 函数是比较简单的，但有时我们需要对爬取进行更复杂的处理。例如我们用上面的代码去爬取豆瓣读书网站上的页面，则会失败。

```
url := "https://book.douban.com/subject/1007305/"
var f collect.Fetcher= collect.BaseFetch{}
body, err := f.Get(url)
```

报错为`Error status code:418`，服务器会返回一个不正常的状态码，并且没有正常的 HTML 内容。

为什么这个网站可以通过浏览器正常访问，但是通过程序却不行呢？这二者的区别在哪里？

显然，豆瓣现在有一些反爬机制阻止了我们对服务器的访问。如果我们使用浏览器的开发者工具（一般在 windows 下为 F12 快捷键），或者通过 wireshark 等抓包工具查看数据包，会看到浏览器自动在 HTTP Header 中设置了很多内容，其中比较重要的一个就是 **User-Agent 字段，它可以表明当前正在使用的应用程序、设备类型和操作系统的类型与版本。**

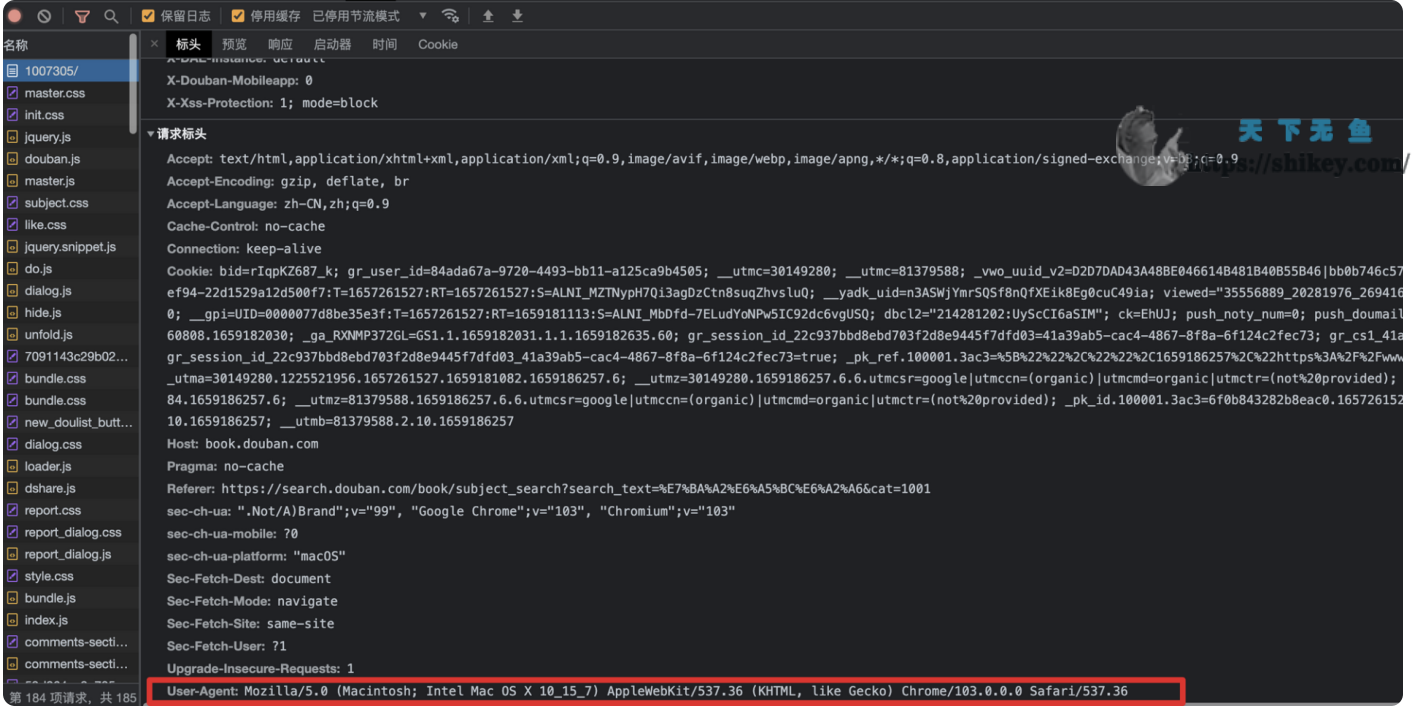

大多数浏览器使用以下格式发送 **User-Agent：**

```
Mozilla/5.0 (操作系统信息) 运行平台(运行平台细节) <扩展信息>
```

我当前的 Chrome（谷歌浏览器）发送的信息如下：

```
Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7) AppleWebKit/537.36 (KHTML, like
```

其中，Mozilla/5.0 由于历史原因，是现在的主流浏览器都会发送的。

`Macintosh; Intel Mac OS X 10_15_7` 代表当前操作系统的版本号。

`AppleWebKit/537.36` 是在 Apple 设备上使用的 Web 渲染引擎标识符。

`KHTML`是在 Safari 和 Chrome 上使用的引擎。

`Chrome/103.0.0.0  Safari/537.36` 指代浏览器的名字和版本号。

使用不同的浏览器、设备，User-Agent 都会略有不同。不同应用程序的 User-Agent 参考如下：

复制代码

```
Lynx: Lynx/2.8.8pre.4 libwww-FM/2.14 SSL-MM/1.4.1 GNUTLS/2.12.23

Wget: Wget/1.15 (linux-gnu)

Curl: curl/7.35.0

Samsung Galaxy Note 4: Mozilla/5.0 (Linux; Android 6.0.1; SAMSUNG SM-N910F Buil

Apple iPhone: Mozilla/5.0 (iPhone; CPU iPhone OS 10_3_1 like Mac OS X) AppleWeb

Apple iPad: Mozilla/5.0 (iPad; CPU OS 8_4_1 like Mac OS X) AppleWebKit/600.1.4

Microsoft Internet Explorer 11 / IE 11: Mozilla/5.0 (compatible, MSIE 11, Windo
```

有时候，我们的爬虫服务需要动态生成 User-Agent 列表，方便在测试、或者在使用代理大量请求单一网站时，动态设置不同的 User-Agent（我会在后面的课程中给出相关的代码）。

因为有些服务器会检测 User-Agent，以此识别请求是否是特定的应用程序发出的，阻止爬虫机器人访问服务器。而使用正确的 User-Agent 会让我们的请求看起来更有“人性”，让我们能够更自由地从目标网站收集数据。

接下来我们就来实验一下。如下所示，我们创建一个新的结构体 BrowserFetch 并让其实现 Fetcher 接口。为了能够设置 HTTP 请求头，我们不能够再使用简单的 http.Get 方法了。

我们首先要创建一个 HTTP 客户端 http.Client，然后通过 http.NewRequest 创建一个请求。在请求中调用 req.Header.Set 设置 User-Agent 请求头。最后调用 client.Do 完成 HTTP 请求。

复制代码

```
type BrowserFetch struct {
}

//模拟浏览器访问
func (BrowserFetch) Get(url string) ([]byte, error) {
  client := &http.Client{}

  req, err := http.NewRequest("GET", url, nil)
  if err != nil {
```

```
    return nil, fmt.Errorf("get url failed:%v", err)
  }

  req.Header.Set("User-Agent", "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_4)

  resp, err := client.Do(req)
  if err != nil {
    return nil, err
  }

  bodyReader := bufio.NewReader(resp.Body)
  e := DeterminEncoding(bodyReader)
  utf8Reader := transform.NewReader(bodyReader, e.NewDecoder())
  return ioutil.ReadAll(utf8Reader)
}
```


其实 http.Get 方法之所以简单，只是对上面这些步骤完成了封装。如下所示，http.Get 会默认生成内置的 http.Client，创建请求 NewRequest，并调用 client.Do 函数，client.Do 最终会调用 Transport.roundTrip 函数发送请求。

复制代码

```
var DefaultClient = &Client{}
func Get(url string) (resp *Response, err error) {
  return DefaultClient.Get(url)
}

func (c *Client) Get(url string) (resp *Response, err error) {
  req, err := NewRequest("GET", url, nil)
  if err != nil {
    return nil, err
  }
  return c.Do(req)
}

```

现在我们只要在 main 函数中将采集引擎替换为 collect.BrowserFetch，就可以轻松获取到豆瓣网站中的内容了。

复制代码

```
func main() {
  url := "https://book.douban.com/subject/1007305/"
  var f collect.Fetcher = collect.BrowserFetch{}
  body, err := f.Get(url)
  if err != nil {
    fmt.Println("read content failed:%v", err)
```

```
    return
  }
  fmt.Println(string(body))
}
```

远程访问浏览器

仅仅在请求头中传递 User-Agent 是不够的。正如我们之前提到过的，浏览器引擎会对 HTML 与 CSS 文件进行渲染，并且执行 JavaScript 脚本，还可能会完成一些实时推送、异步调用工作。这导致内容会被延迟展示，无法直接通过简单的 http.Get 方法获取到数据。

更进一步的，有些数据需要进行用户交互，例如我们需要点击某些按钮才能获得这些信息。这就迫切地需要我们具有模拟浏览器的能力，或者更简单一点：直接操作浏览器，让浏览器来帮助我们爬取数据。

要借助浏览器的能力实现自动化爬取，目前依靠的技术有以下三种：

- 借助浏览器驱动协议（WebDriver protocol）远程与浏览器交互；
- 借助谷歌开发者工具协议（CDP，Chrome DevTools Protocol）远程与浏览器交互；
- 在浏览器应用程序中注入要执行的 JavaScript，典型的工具有 Cypress， TestCafe。

由于第三种技术通常只用于测试，所以下面我们就重点来说说前面两种技术。

Webdriver Protocol

Webdriver 协议是操作浏览器的一种远程控制协议。借助 Webdriver 协议完成爬虫的框架或库有 Selenium，WebdriverIO，Nightwatch，其中最知名的就是 Selenium。Selenium 为每一种语言（例如 Java、Python、Ruby 等）都准备了一个对应的 clinet 库，它整合了不同浏览器的驱动（这些驱动由浏览器厂商提供，例如谷歌浏览器的驱动和火狐浏览器的驱动）。

Selenium 通过 W3C 约定的 WebDriver 协议与指定的浏览器驱动进行通信，之后浏览器驱动操作特定浏览器，从而实现开发者操作浏览器的目的。由于 Selenium 整合了不同的浏览器驱动，因此它对于不同的浏览器都具有良好的兼容性。

Chrome DevTools Protocol

第二种远程与浏览器交互的协议叫做Chrome DevTools Protocol（谷歌开发者工具协议）。顾名思义，该协议最初是由谷歌开发者工具团队维护的，负责调试、操作浏览器的协议。目前，现代大多数浏览器都支持谷歌开发者工具协议。我们经常使用到的谷歌浏览器的开发者工具（快捷键 CTRL + SHIFT + I 或者 F12）就是使用这个协议来操作浏览器的。

查看谷歌开发者工具与浏览器交互的协议的方式是，打开谷歌浏览器，在开发者工具 → 设置 → 实验中勾选 Protocol Monitor（协议监视器）。

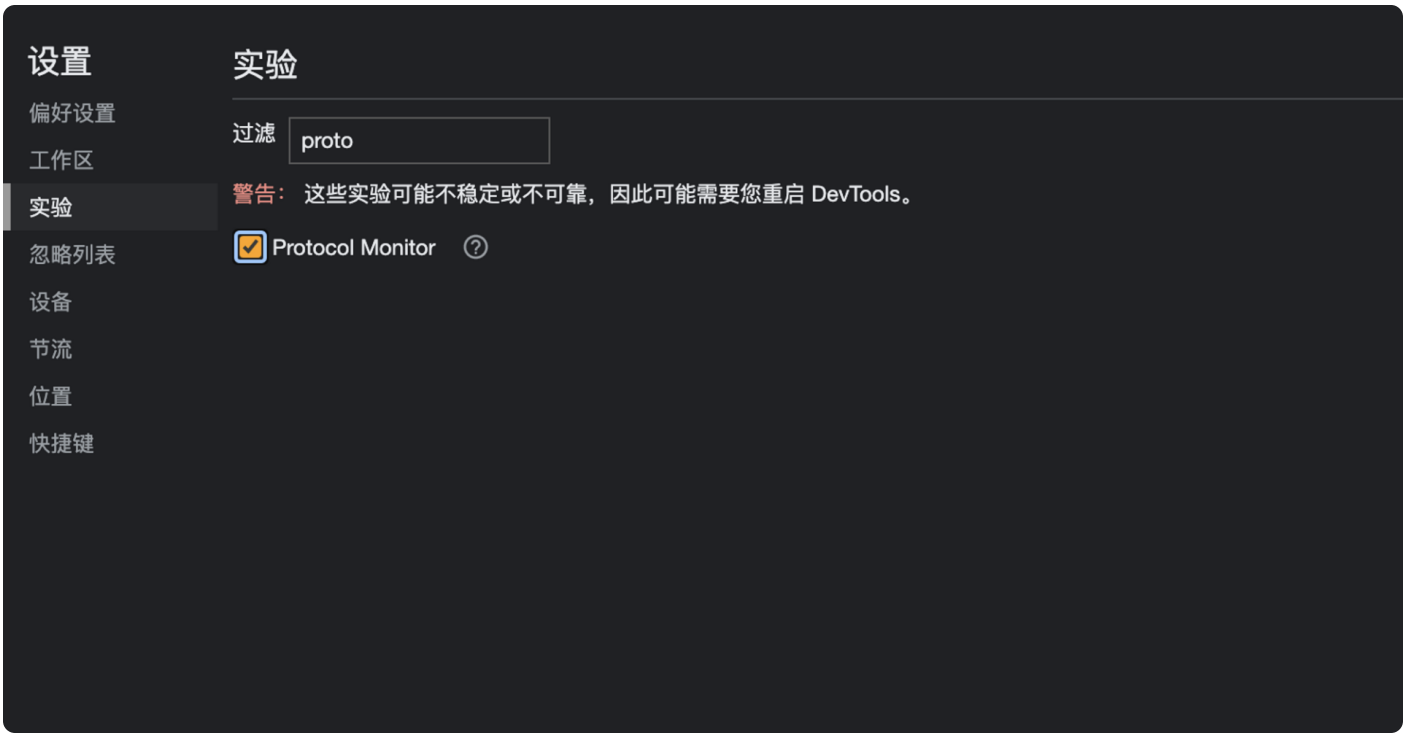

接下来，我们要重启开发者工具，在右侧点击更多工具，这样就可以看到协议监视器面板了。面板中有开发者工具通过协议与浏览器交互的细节。

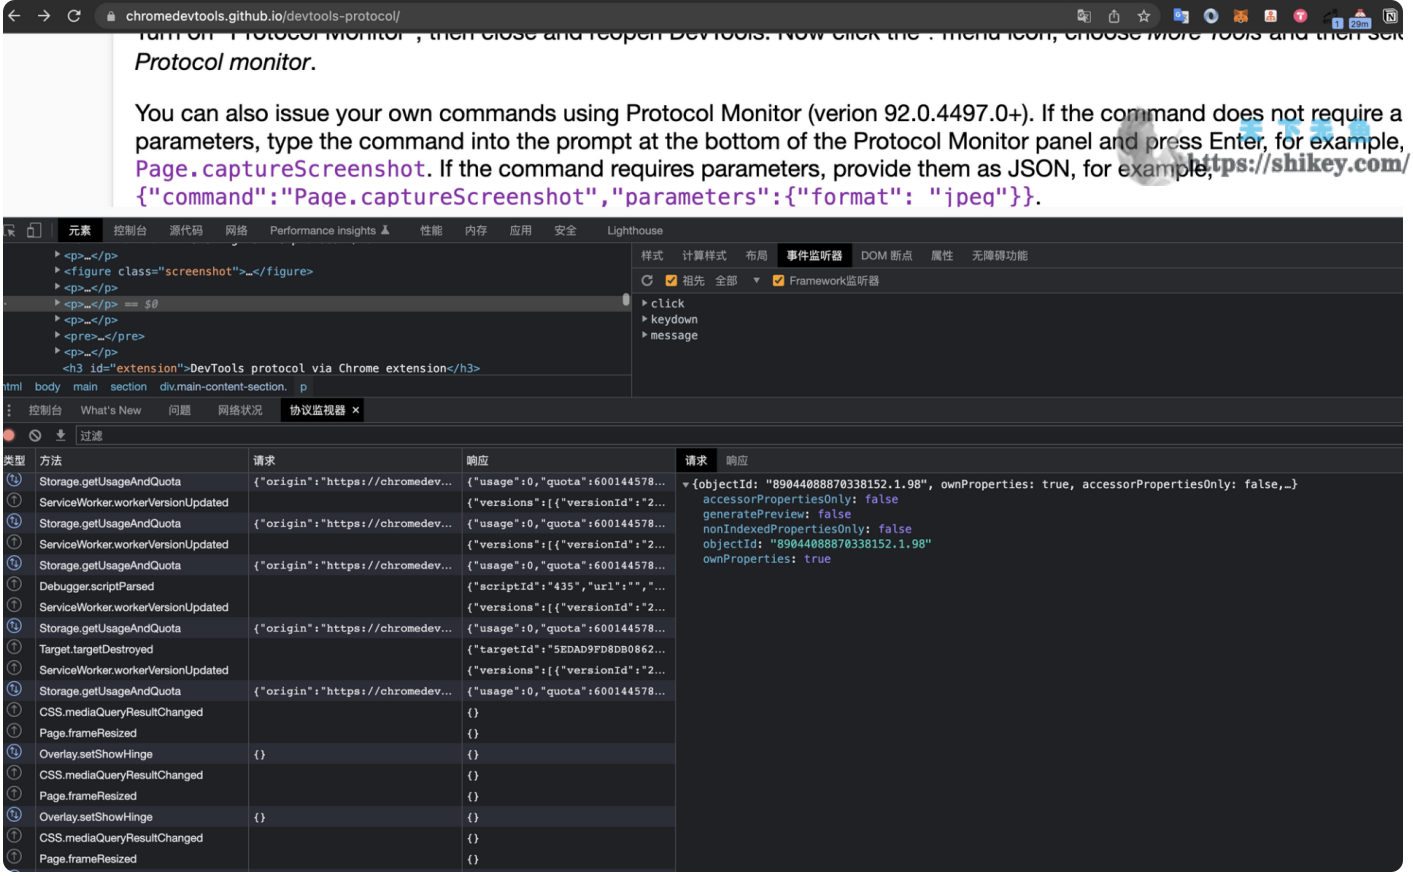

与 Selenium 需要与浏览器驱动进行交互不同的是，Chrome DevTools 协议直接通过 Web Socket 协议与浏览器暴露的 API 进行通信，这使得 Chrome DevTools 协议操作浏览器变得更快。

所以，相比 Selenium，我更推荐使用 Chrome DevTools 协议来访问浏览器。Selenium 4 虽然已经提供了对于 Chrome DevTools 协议的支持，但是它目前还没有对 Go 的官方的 Client 库。

在 Go 中实现了 Chrome DevTools 协议的知名第三方库是 chromedp。它的操作简单，也不需要额外的依赖。借助 chromedp 提供的能力与浏览器交互，我们就具有了许多灵活的能力，例如截屏、模拟鼠标点击、提交表单、下载 / 上传文件等。chromedp 的一些操作样例你可以参考 example 代码库。

这里我模拟鼠标点击事件，给你做一个演示。假设我们访问 Go time 包的说明文档，例如 After 函数，会发现下图的参考代码是折叠的。

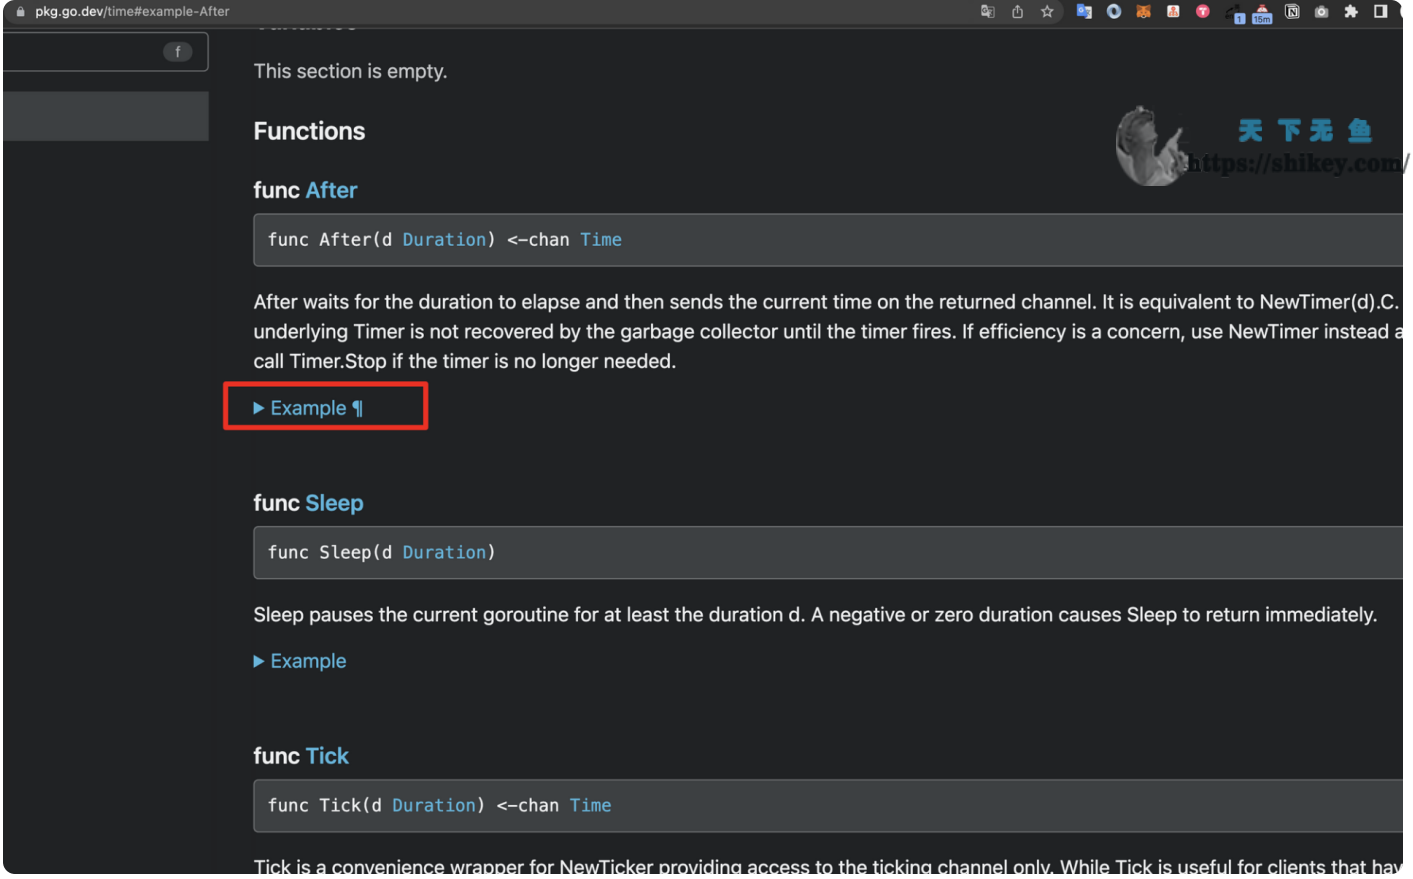

通过鼠标点击，折叠的代码可以展示出 time.After 函数的参考代码。

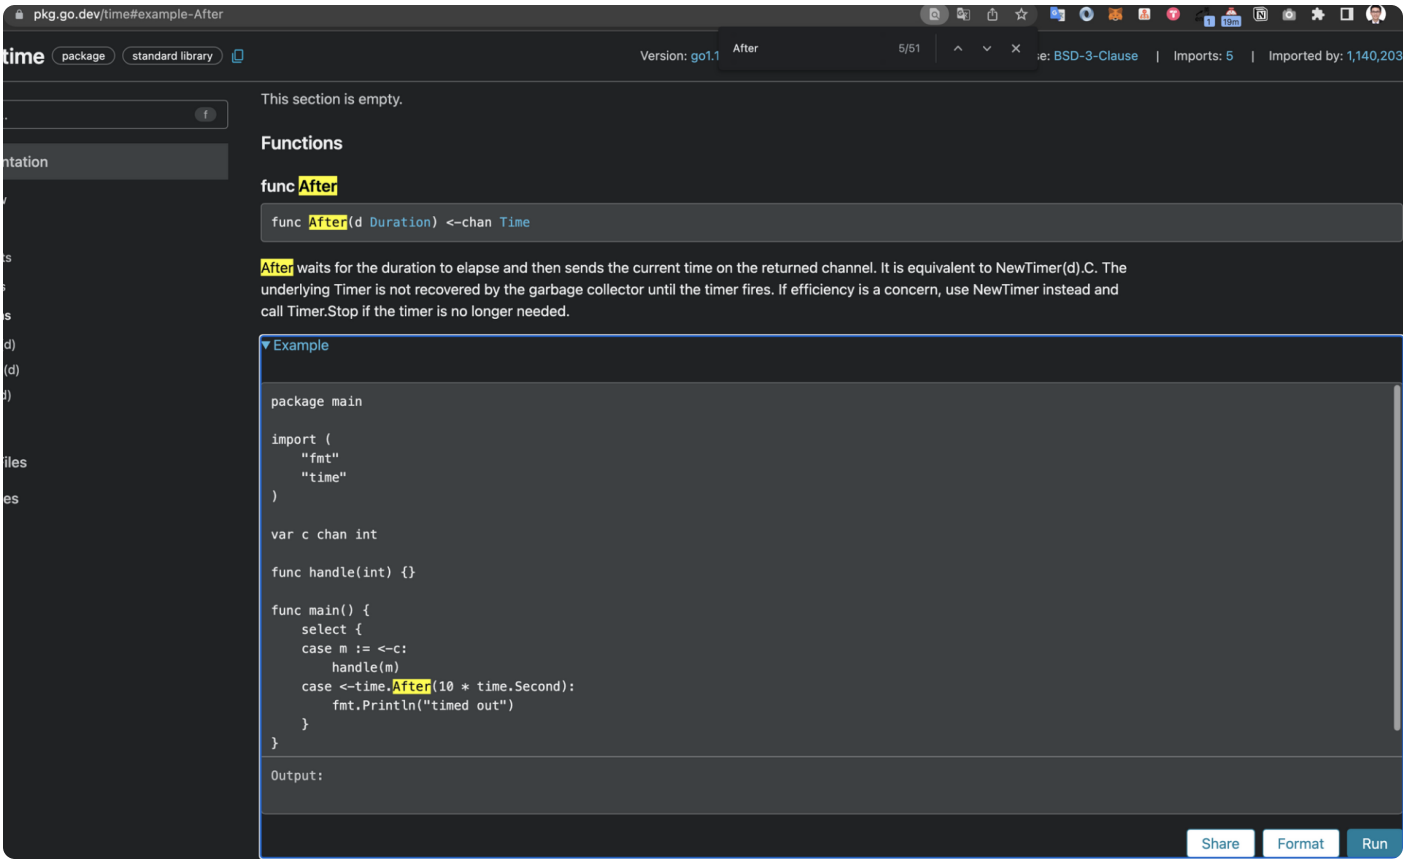

我们经常面临这种情况，即需要完成一些交互才能获取到对应的数据。要模拟上面的完整操作，代码如下所示：

复制代码


```go
package main

import (
  "context"
  "log"
  "time"

  "github.com/chromedp/chromedp"
)

func main() {
  // 1、创建谷歌浏览器实例
  ctx, cancel := chromedp.NewContext(
    context.Background(),
  )
  defer cancel()

  // 2、设置context超时时间
  ctx, cancel = context.WithTimeout(ctx, 15*time.Second)
  defer cancel()

  // 3、爬取页面，等待某一个元素出现,接着模拟鼠标点击，最后获取数据
  var example string
  err := chromedp.Run(ctx,
    chromedp.Navigate(`https://pkg.go.dev/time`),
    chromedp.WaitVisible(`body > footer`),
    chromedp.Click(`#example-After`, chromedp.NodeVisible),
    chromedp.Value(`#example-After textarea`, &example),
  )
  if err != nil {
    log.Fatal(err)
  }
  log.Printf("Go's time.After example:\\n%s", example)
}
```

解释一下。**首先我们导入了 chromedp 库，并调用 chromedp.NewContext 为我们创建了一个浏览器的实例。**它的实现原理非常简单，即查找当前系统指定路径下指定的谷歌应用程序，并默认用无头模式（Headless 模式）启动谷歌浏览器实例。通过无头模式，我们肉眼不会看到谷歌浏览器窗口的打开过程，但它确实已经在后台运行了。

复制代码

```go
func findExecPath() string {
  var locations []string
  switch runtime.GOOS {
  case "darwin":
    locations = []string{
```

```
      // Mac
      "/Applications/Chromium.app/Contents/MacOS/Chromium",
      "/Applications/Google Chrome.app/Contents/MacOS/Google Chrome",
    }
  case "windows":
    locations = []string{
      // Windows
      "chrome",
      "chrome.exe", // in case PATHEXT is misconfigured
      `C:\\Program Files (x86)\\Google\\Chrome\\Application\\chrome.exe`,
      `C:\\Program Files\\Google\\Chrome\\Application\\chrome.exe`,
      filepath.Join(os.Getenv("USERPROFILE"), `AppData\\Local\\Google\\Chrome\\
      filepath.Join(os.Getenv("USERPROFILE"), `AppData\\Local\\Chromium\\Applic
    }
  default:
    locations = []string{
      // Unix-like
      "headless_shell",
      ...
    }
  }
```


所以说，当前程序能够运行的重要前提是在指定路径中存在谷歌浏览器程序。当然，一般我们系统中可浏览的谷歌浏览器的大小都是比较大的，所以 chromedp 还好心地为我们提供了一个包含了无头谷歌浏览器的应用程序的镜像：headless-shell。

第二步，用 context.WithTimeout 设置当前爬取数据的超时时间，这里我们设置成了 15s。

第三步，chromedp.Run 执行多个 action，chromedp 中抽象了 action 和 task 两种行为。其中，action 指的是爬取、等待、点击、获取数据这样的行为。而 task 指的是一个任务，task 是多个 action 的集合。因此，chromedp.Run 会将多个 action 封装为一个任务，并依次执行。

复制代码

```
func Run(ctx context.Context, actions ...Action) error {
  ...
  return Tasks(actions).Do(cdp.WithExecutor(ctx, c.Target))
}
```

- chromedp.Navigate 指的是爬取指定的网址：https://pkg.go.dev/time。

- chromedp.WaitVisible 指的是“等待当前标签可见”，其参数使用的是 CSS 选择器的形式。
  在这个例子中，body > footer 标签可见，代表正文已经加载完毕。
- chromedp.Click 指的是“模拟对某一个标签的点击事件”。
- chromedp.Value 用于获取指定标签的数据。
  最终代码执行结果如下，这样我们就成功获取到了 time.After 的代码示例。

复制代码

```
2022/10/24 17:26:46 Go's time.After example:
package main

import (
        "fmt"
        "time"
)

var c chan int

func handle(int) {}

func main() {
        select {
        case m := <-c:
                handle(m)
        case <-time.After(10 * time.Second):
                fmt.Println("timed out")
        }
}
```

在后面的课程中，我们还会对chromedp进行封装，实现我们定义的采集引擎的接口。你也可以先试着使用chromedp来构建一下自己的采集引擎。

可以看到，接口在这里再次发挥了巨大作用。只要合理地组合设计，我们的程序就可以很方便地切换任何的采集引擎。不管是用原生还是模拟浏览器方式，不管是使用 Selenium、chromedp 的方式，亦或是未来新的采集方式，都不会破坏我们其他模块的代码。

空接口

好了，前面我们介绍的接口都是带有方法签名的。其实还有一类特殊的接口不带任何的方法签名，被称为空接口。我们在后面的项目中还会频繁使用到它。

任何类型都隐式实现了空接口。正如 Go 的创始人 Rob Pike 所说：“Empty interface say nothing”，空接口并没有任何的含义，既然如此，空接口有什么作用呢？

由于 Go 是强类型的语言，使用空接口可以为外界提供一个更加通用的能力。然而在处理接口的过程中却需要默默承受解析空接口带来的痛苦。通过使用空接口，常见的 fmt.Println 函数提供了打印任何类型的功能。

```
func Println(a ...interface{}) (n int, err error) {
  return Fprintln(os.Stdout, a...)
}
```

如果不使用空接口，那么每一个类型都需要实现一个对应的 Println 函数，是非常不方便的。

不过，空接口带来便利的同时，也意味着我们必须在内部解析接口的类型，并对不同的类型进行相应的处理。以 fmt.Println 为例，Println 函数内部通过检测接口的具体类型来调用不同的处理函数。如果是自定义类型，还需要使用反射、递归等手段完成复杂类型的打印功能。

```
func (p *pp) printArg(arg interface{}, verb rune) {
    switch f := arg.(type) {
      case bool:
        p.fmtBool(f, verb)
      case float32:
        p.fmtFloat(float64(f), 32, verb)
      case float64:
        p.fmtFloat(f, 64, verb)
      case complex64:
        p.fmtComplex(complex128(f), 64, verb)
      ....
}
```

类似的 API 设计还有用于序列化与反序列化的 JSON 标准库等。

```
func Marshal(v interface{}) ([]byte, error) {
  e := newEncodeState()

  err := e.marshal(v, encOpts{escapeHTML: true})
```

```
  if err != nil {
    return nil, err
  }
  buf := append([]byte(nil), e.Bytes()...)

  encodeStatePool.Put(e)

  return buf, nil
}
```


JSON 标准库内部使用了反射来判断接口中存储的实际类型，以此分配不同的序列化器。

复制代码

```
func newTypeEncoder(t reflect.Type, allowAddr bool) encoderFunc {
  ...
  switch t.Kind() {
    case reflect.Bool:
      return boolEncoder
    case reflect.Int, reflect.Int8, reflect.Int16, reflect.Int32, reflect.Int64
      return intEncoder
    case reflect.Uint, reflect.Uint8, reflect.Uint16, reflect.Uint32, reflect.U
      return uintEncoder
      ...

}
```

除此之外，对于跨服务调用的 API，使用空接口可以提高它们的扩展性。因为在这种场景下，修改 API 的成本通常比较高，服务器需要改造并发布新的 SDK，客服端还需要适配新的 SDK 并联调测试。

如下所示，在 Info 结构体中增加扩展类型 `map[string]interface{}`，新的功能如果需要传递新的信息，当前服务甚至可以不用修改 API。

复制代码

```
type info struct{
  ExtraData              map[string]interface{}        `json:"extra_data"`
  ...
}
```

在后面的课程中我们还会看到，由于爬虫爬取的数据是多种多样的，我们也会用空接口来实现数据存储的拓展性。

可以看出，空接口为 API 带来了扩展性和灵活性，但是也为模块的内部处理增加了额外的成本。因为 API 内部处理空接口时使用了大量的反射，而反射通常比较消耗性能。在实际项目中，当我们 JSON 序列化一个复杂的结构体时，有时候会有上百毫秒的耗时。

空接口与反射

空接口是实现反射的基础，因为空接口中会存储动态类型的信息，这为我们提供了复杂、意想不到的处理能力和灵活性。我们可以获取结构体变量内部的方法名、属性名，能够动态地检查函数或方法的参数个数和返回值个数，也可以在运行时通过函数名动态调用函数。这些能力不使用反射都无法做到。

举一个例子，假如现在有一个 Student 结构体：

复制代码

```
type Student struct {
  Age int
  Name string
}
```

如果我们希望写一个可以将该结构体转换为 SQL 语句的函数，按照过去的实现方式，可以为这个结构体添加一个 CreateSQL 方法：

复制代码

```
func (s*Student) CreateSQL() string{
  sql := fmt.Sprintf("insert into student values(%d, %s)", s.Age, s.Name)
  return sql
}
```

这样当调用 CreateSQL 方法时，可以生成一条 SQL 语句：

复制代码

```
func main() {
  o := Student{
    Age: 20,
    Name: "jonson",
  }
  fmt.Println(o.CreateSQL())
}
```

结果打印为：

复制代码

```
insert into student values(20, jonson)
```

但是，假如我们的其他结构体也有相同的需求呢？很显然，按照之前学过的知识，我们可以为每个类型都添加一个 CreateSQL 方法，并生成一个接口：

复制代码

```
type SQL interface{
  func CreateSQL() string
}
```

这种方法在项目初期，以及结构体类型简单的时候是比较方便的。但是如果项目中定义的类型非常多，而且可能当前类型还没有被创建出来（需要运行时创建，或者通过远程过程调用触发），我们就要书写很多逻辑相同的重复代码。有没有一种更加简单通用的办法可以解决这一类问题呢？如果可以在运行时探测到结构体变量中的方法名就好了。

这恰恰就是反射为我们提供的便利。如下所示，我们可以将上面的场景改造成反射的形式。在 createQuery 函数中，我们可以传递任何的结构体类型，该函数会遍历结构体中所有的字段，并构造 Query 字符串。

复制代码

```
func createQuery(q interface{}) string{
  // 判断类型为结构体
  if reflect.ValueOf(q).Kind() == reflect.Struct {
    // 获取结构体名字
    t := reflect.TypeOf(q).Name()
    // 查询语句
    query := fmt.Sprintf("insert into %s values(", t)
    v := reflect.ValueOf(q)
    // 遍历结构体字段
    for i := 0; i < v.NumField(); i++ {
      // 判断结构体类型
      switch v.Field(i).Kind() {
      case reflect.Int:
        if i == 0 {
          query = fmt.Sprintf("%s%d", query, v.Field(i).Int())
```

```
        } else {
          query = fmt.Sprintf("%s, %d", query, v.Field(i).Int())
        }
      case reflect.String:
        if i == 0 {
          query = fmt.Sprintf("%s\\"%s\\"", query, v.Field(i).String())
        } else {
          query = fmt.Sprintf("%s, \\"%s\\"", query, v.Field(i).String())
        }
        ...
      }
    }
    query = fmt.Sprintf("%s)", query)
    fmt.Println(query)
    return query
  }
}
```


现在，假设我们新建了一个 Trade 结构体，任意结构体都可以通过 createQuery 方法完成构建过程。

复制代码

```
type Trade struct {
  tradeId int
  Price int
}

func main(){
  createQuery(Student{Age: 20, Name: "jonson",})
  createQuery(Trade{tradeId: 123, Price: 456,})
}
```

结果输出为：

复制代码

```
insert into Student values(20, "jonson")
insert into Trade values(123, 456)
```

通过反射，我们动态获取到了结构体中字段的名字，这样就可以灵活生成 SQL 语句了。

如果我们把上面这个例子中的函数改造为递归，然后处理更多的类型，这个函数将更加具备通用性，甚至可以作为一个好用的第三方库了。

接口的陷阱

刚才我们说了接口的很多好处，但是由于接口的特性和内部实现，使用接口时也容易出现几类经典的错误。

第一类错误是，当接口中存储的是值，但是结构体是指针时，接口动态调用无法编译通过。如下所示：

复制代码

```
type Binary struct {
  uint64
}
type Stringer interface {
  String() string
}
func (i *Binary) String() string {
  return "hello world"
}
func main(){
  a:= Binary{54}
  b := Stringer(a)
  b.String()
}
```

Go 语言在编译时阻止了这样的写法，原因在于这种写法会让人产生困惑。如果转换为接口的是值， 那么由于内存逃逸，在转换为接口时必定已经把值拷贝到了堆区。因此如果允许这种写法存在，那么即便看起来在方法中修改了接口中的值，却无法修改原始值，这非常容易引起误解。

第二类错误是将类型切片转换为接口切片。如下所示：

复制代码

```
func foo() []interface{} {
  return []int{1,2,3}
}
```

这种情况仍然会在编译时报错：

复制代码

```
cannot use []int literal (type []int) as type []interface {} in return argument
```

Go 语言禁止了这种写法，就像前面所说的，批量转换为接口是效率非常低的操作，因为每个元素都需要完成内存逃逸的额外开销。

接口的第三类陷阱涉及接口与 nil 之间的关系。当接口为 nil 时，接口中的动态类型 itab 和动态类型值 data 必须都为 nil，初学者常常会在这个问题上犯错。例如在下面的 foo 函数中，由于返回的 err 没有任何动态类型和动态值，因此 err 等于 nil。

复制代码

```
func foo() error {
  var err error // nil
  return err
}
func main() {
  err := foo()
  fmt.Println(err == nil) // true
}
```

然而，如果在 foo 函数中将错误类型定义为自定义类型，例如 *os.PathError ，我们会发现 err 不等于 nil。

复制代码

```
func foo() error {
  var err *os.PathError
  return err
}
func main() {
  err := foo()
  fmt.Println(err != nil) // true
}
```

这是因为当接口为 nil 时，代表接口中的动态类型和动态类型值都为 nil，而当前由于接口 error 具有动态类型 *os.PathError，接口的内部结构体 itab 不为空。如下图所示：

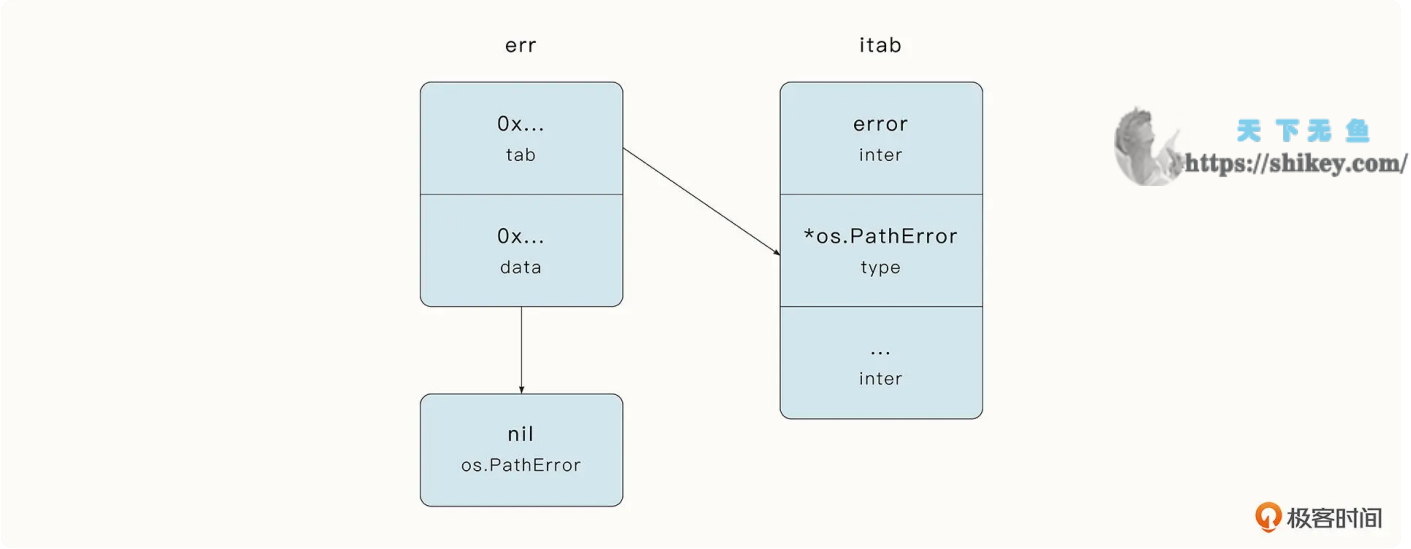

避免这一问题需要谨慎地使用自定义的 Error 作为定义，而更多的使用内置的 errors.New 或 fmt.Errorf 来生成和包裹错误。我在之后的课程还会详细介绍错误处理的最佳实践。

总结

这节课，我们通过一个模拟浏览器访问的案例实战了采集引擎的抽象。**由于 User-Agent 标识了应用程序的类型和版本，所以我们将 User-Agent 设置成了真实浏览器的值，绕过了这个例子中服务器的反爬机制。**不过这只是众多反爬机制中最简单的一种，通过对采集引擎接口的抽象，我们能够比较轻松地实现采集引擎的切换，并进行模块化的测试。

带方法的接口帮助我们完成了功能的模块化，而不带方法的空接口则增加了 API 的扩展性。同时，空接口是反射实现的基础，有了它我们才能有“获取字段名”、“通过函数名动态调用方法”这样复杂灵活的能力，因此空接口在一些基础库、RPC 框架中的应用也非常广泛。

不过空接口带给我们的扩展性也有一定的代价，那就是它的内部需要解析繁琐的多种类型，使用反射导致效率变低。

课后题

最后，我也给你留一道思考题。

如果一个网站需要登录才可以访问，我们应该如何实现自动登录的能力？

欢迎你在留言区与我交流讨论，我们下节课再见！

上一篇　20 | 面向组合：接口的使用场景与底层原理

精选留言

写留言

> 由作者筛选后的优质留言将会公开显示，欢迎踊跃留言。